

AI智能客服售前跟进系统

技术方案手册（软件项目交付标准版）

项目定位	抖音小风车手机号线索驱动的个人微信AI销售预跟进系统
文档版本	v1.3
文档日期	2026-05-24
预算基线	87,000元（58人天 × 1500元/人天）
实施周期	6-8周
范围基线	第一期自用MVP；后续SaaS化、复杂权限、计费和高可用另行评估
交付口径	按软件项目标书式交付：范围、质量、验收、缺陷、变更、交付物均可追踪

本手册用于立项、开发、测试、灰度、验收和后续变更管理。除双方书面确认外，本文档与报价单共同构成本期MVP交付基线。

1. 项目目标与第一性原理

本项目的本质不是建设一个通用聊天机器人，而是建设一个“线索到销售接管”的工程系统。AI的职责是提升首次响应、暖场、识别意向和减少无效沟通；最终成交仍由真人销售完成。

- 业务目标：将抖音小风车手机号线索更快、更稳定地推进到销售接管。
- 工程目标：让线索状态、会话绑定、AI回复、图文识别、风控接管和失败追踪形成闭环。
- 设计原则：保留必要复杂度，避免把MVP做成完整SaaS、复杂坐席系统或通用AI平台。
- 边界原则：模型只生成候选表达和理解结果，业务事实、敏感字段和最终发送权必须受系统规则约束。

2. MVP范围基线

类别	内容	验收口径
包含	手机号线索导入、销售分配、个人微信手机号加好友、备注绑定、文字AI回复、图片另存、视觉理解、图文自动回复、本地车源索引、大风车基础适配、销售接管、日志与失败重试	以端到端闭环演示和验收用例通过为准
不包含	完整SaaS、多租户计费、复杂权限、抖音官方API、复杂BI、模型微调平台、高可用集群、长期运维、完整坐席系统	不作为本期验收项；新增时走变更流程
甲方前提	微信测试电脑、测试销售微信、小风车线索样本、大风车参数、千问视觉API Key、销售接管规则、图片测试样本	未按期提供时，交付周期相应顺延


3. 质量属性与非功能要求

质量属性	工程要求	MVP验收基线
功能性	覆盖线索导入、分配、加好友、会话绑定、文字回复、图片回复、转人工、审计	A类验收用例通过；核心流程可重复演示
性能效率	实时对话链路不做重型同步外部依赖；车源查询优先本地索引	性能数值仅作为优化目标，不作为未经压测的硬验收承诺；最终以测试环境实测数据为准
兼容性	明确Windows、微信桌面端、模型API、大风车API的适配边界	指定测试环境通过；版本升级需回归测试
易用性	销售只需在个人微信中正常接管；管理员可查看任务、失败原因和基本状态	无需销售理解AI后台即可使用
可靠性	任务幂等、失败重试、Worker心跳、断点恢复、模型失败降级	灰度验收时S1缺陷为0；失败任务可追踪
安全性	手机号、图片、密钥、车主隐私和底价信息分级处理	敏感字段不进入AI可见上下文；日志不明文记录密钥
维护性	模块边界清晰，配置、Prompt、规则、接口适配分层	新增模型/车源适配不改动核心状态机
可移植性	本地Worker、模型Provider、车源Provider通过适配层隔离	更换模型或部署机器时保留主业务状态

性能指标口径

本期MVP的核心交付标准是系统能根据客户消息正常回复，或在无法安全回复、识别失败、命中风险规则时触发人工接管。文字回复、图片回复和管理页查询的具体耗时可作为灰度阶段优化目标，但不作为未经压测的硬性验收承诺，最终以测试环境、账号状态、网络质量、模型服务和真实样本的实测数据为准。

4. 总体架构



系统保持“业务控制面 + 本地RPA Worker + OmniAuto AI引擎 + 图片理解 + 车源索引 + Guard接管”的六层边界。该设计的核心是让微信操作、AI生成、业务状态和风控规则互不混杂，便于测试、排障和后续扩展。

主流程

手机线索 -> 销售分配 -> 加好友任务 -> 微信备注绑定 -> 会话监听 -> OmniAuto生成候选回复 -> Guard检查 -> 自动回复或人工接管 -> 审计记录

5. 模块边界与职责

模块	主要职责	不得承担的职责
业务控制面	线索、销售、任务、状态、审计、配置	不直接操作微信UI
RPA Worker	加好友、备注、监听消息、保存图片、发送回复、心跳上报	不保存业务主状态，不自行决定销售策略
OmniAuto AI引擎	上下文管理、RAG、候选回复生成、图文回复编排	不直接读取底价/车主隐私，不绕过Guard发送
AI Reply Provider Adapter	预留Dify/FastGPT/其他模型工作流接入	不作为第一期业务主状态库
图片/视觉模块	图片保存、视觉识别、结构化ImageIntent	不直接生成最终客服话术
车源服务	同步大风车、清洗字段、建立本地索引、字段白名单	不把敏感价格和车主隐私传给AI
Guard/接管	风险判断、停止规则、转人工、发送前校验	不依赖单一Prompt判断高风险

6. 本地Worker可视化执行台

Worker不应设计成完全不可见的后台脚本。第一期应参照“微信窗口 + 本地执行台”的形态：左侧由销售电脑正常打开微信桌面客户端，右侧Worker执行台展示当前客户、任务步骤、视觉截图、AI处理结果、发送结果和运行控制。

区域	内容	验收口径
任务状态	显示当前线索、绑定销售、微信会话、执行阶段、成功/失败状态	销售或管理员能判断当前Worker正在做什么
步骤时间线	按顺序展示检查微信、读取消息、图片另存、视觉识别、回复生成、发送完成、转人工等步骤	每一步有状态和时间，不只显示最终结果
画面证据	保留当前微信窗口截图或图片缩略图，用于确认识别对象	排障时能看到当时处理的是哪条消息/哪张图片

区域	内容	验收口径
AI结果	展示视觉理解摘要、候选回复、Guard结论、最终发送内容	能复盘AI为什么这样回复
运行控制	提供启动、暂停、继续、停止、手动接管/禁用AI等按钮	异常时可以人工停止，不依赖杀进程
健康状态	显示Worker心跳、微信连接状态、模型连接状态、车源同步状态	状态异常可见
日志入口	显示最近错误、失败原因、任务ID和会话ID	失败任务可追踪

设计约束

- 执行台只负责本机运行可视化和人工控制，不作为业务主数据库。
- 执行台不得展示采购价、销售底价、经理价、车主隐私和API密钥。
- 第一期不要求做复杂坐席工作台，只要求做到本机可观察、可暂停、可恢复、可复盘。
- 当销售手动接管或点击停止后，该会话AI自动回复必须停止。

7. 核心数据流与状态机

对象	状态流转	关键规则
线索	new -> assigned -> add_friend_pending -> add_friend_sent -> friend_added -> ai_chatting -> handoff_required -> human_taken_over -> closed	状态变更必须记录时间、触发来源和失败原因
加好友任务	pending -> running -> sent -> failed -> expired	按任务ID幂等执行；失败可重试但不得重复骚扰客户
会话	unbound -> bound -> ai_active -> handoff_open -> human_active -> stopped	销售手动发送后AI停止；人工接管状态优先级最高
图片资产	received -> saved -> recognized -> linked -> replied/failed	保存路径、来源消息、识别结果和回复结果可追踪

8. AI对话与RAG架构

第一期以OmniAuto作为主对话控制引擎。Dify或FastGPT可作为后续候选回复Provider接入，但不直接接管业务状态、车源敏感字段和最终发送权。

层次	职责	实现口径
知识来源	稳定知识、销售话术、二手车规则、车型资料、服务流程	进入OmniAuto知识库/RAG
动态事实	车源、价格、里程、状态、图片	来自大风车同步后的本地结构化索引
候选回复	根据上下文、知识和事实生成表达	默认OmniAuto；可通过Adapter调用Dify/FastGPT
发送前检查	敏感承诺、越权报价、车况断言、金融承诺、接管触发	由Guard执行，不能只靠模型自觉
审计	记录输入、召回、候选回复、Guard结论、最终动作	用于复盘和验收

图文回复链路

客户图片 -> RPA另存 -> 视觉模型识别 -> ImageIntent -> 本地车源索引 -> evidence pack -> OmniAuto候选回复 -> Guard -> 发送/接管

9. 安全与隐私要求

类别	要求	验收方式
手机号	界面展示可脱敏；日志避免无必要全量输出	抽查日志和页面
图片	本地保存目录受控；保留周期可配置；与线索/会话建立关联	检查配置和样本记录
密钥	大风车、模型API Key不得写入代码和普通日志	代码与日志抽查

类别	要求	验收方式
车源敏感字段	采购价、底价、经理价、车主姓名、身份证、银行卡不得进入AI上下文	构造测试用例验证
Prompt与规则	不得向客户暴露系统提示词、内部规则和模型身份细节	对抗样本测试
权限	第一期只做基础管理入口；后续多角色权限另行评估	不作为本期复杂权限验收

10. 可靠性与异常恢复

场景	处理策略	验收口径
Worker离线	心跳超时标记离线，任务停止派发或进入待重试	离线状态可见
微信窗口异常	记录异常、停止当前任务、允许人工恢复后重试	失败原因可见
重复消息	按消息ID/时间/会话去重，避免重复回复	重复样本不重复发送
模型超时	超时后重试或降级为固定话术/转人工	超时任务不丢失
视觉失败	图片识别失败时使用兜底话术或转人工	失败路径可追踪
大风车失败	对话优先读本地缓存；同步失败告警	接口失败不阻塞普通对话
销售接管	人工接管状态优先级最高，不被AI自动恢复覆盖	销售发言后AI停止准确率100%

11. 兼容性、维护性与可移植性

维度	要求
运行环境	第一期以指定Windows测试电脑和指定微信桌面版本为验收环境；微信升级需回归测试。
模型供应商	通过AI Reply Provider Adapter隔离模型调用，避免把模型供应商写死在业务状态机中。
车源系统	通过Vehicle Provider Adapter封装大风车鉴权、字段清洗和同步任务。
配置项	销售、微信设备、最大轮次、停止规则、视觉模型、车源同步周期应配置化。
测试集	保留文字、图片、风控、接管、车源匹配回归样本，用于版本升级。
部署迁移	控制面数据、知识库、车源索引、运行配置和Worker安装包分离，便于迁移到新机器。

12. 验收标准

编号	验收项	通过标准
A-01	线索导入	可导入手机号线索并进入待分配状态
A-02	销售分配	线索可分配到指定销售和对应微信设备
A-03	加好友任务	RPA可按手机号搜索、发送固定申请语并记录结果
A-04	备注绑定	可生成短码备注并将微信会话绑定回线索
A-05	文字回复	客户文字消息可正常自动回复；若命中风险规则则触发人工接管；回复过程记录审计
A-06	图片回复	客户图片可另存、识别并生成图文回复；若识别失败或命中风险规则则触发人工接管
A-07	车源检索	可基于本地索引返回AI可见字段，不暴露敏感字段
A-08	高风险接管	价格、车况、金融、合同等高风险场景不直接越权承诺
A-09	销售停止AI	销售手动发言后AI自动回复停止，准确率100%

编号	验收项	通过标准
A-10	失败追踪	加好友、图片、模型、车源失败均可查看失败原因
A-11	Worker执行台	可查看当前任务、步骤状态、截图证据、候选回复、Guard结论，并支持暂停/停止
A-12	灰度验收	核心交付标准为能正常回复或触发人工接管；试运行期间S1缺陷为0；S2缺陷修复或双方确认规避

13. 缺陷等级、变更与交付物

等级	定义	处理要求
S1	核心链路不可用，如无法加好友、无法监听、无法发送回复、AI无法停止	阻塞验收，必须修复
S2	核心功能部分失败或存在明显业务风险，如图片链路不稳定、接管状态错误	验收前修复或书面确认规避方案
S3	非核心缺陷，如界面文案、轻微日志展示问题	不阻塞验收，进入遗留清单
S4	优化建议或新增需求	不计入本期缺陷，进入变更或二期需求

变更控制

- 本手册、报价单、验收清单共同构成本期范围基线。
- 新增渠道、完整SaaS、多商户隔离、模型微调、复杂BI、长期运维等均视为范围变更。
- 变更需记录内容、原因、影响模块、追加人天、排期影响和确认人。
- 未经书面确认的口头需求不作为验收依据。

交付物	内容
程序与配置	控制面、Worker、AI配置、车源同步配置、Guard规则配置
测试材料	端到端验收用例、图片样本、风控样本、回归测试结果
部署材料	部署步骤、环境要求、启动/停止方式、常见故障处理
交付记录	缺陷清单、变更记录、验收记录、遗留问题清单

14. 里程碑与当前不做事项

阶段	周期	交付物
P1 启动与基础闭环	第1-2周	线索导入、销售分配、加好友任务、备注规则、任务状态
P2 文字AI闭环	第3-4周	文字回复、上下文绑定、停止规则、审计和基础Guard
P3 图片与图文回复	第5-6周	图片另存、视觉识别、ImageIntent、图文回复、回归样本
P4 车源与灰度验收	第7-8周	大风车基础适配、本地索引、灰度测试、交付文档

当前不做事项

- 不做完整SaaS平台、多租户计费 and 复杂权限。
- 不做大模型微调平台和GPU训练平台。
- 不做全渠道坐席系统和复杂BI报表。
- 不把Dify/FastGPT作为第一期业务主状态系统。
- 不承诺规避微信平台风控或提升微信好友通过率。

15. 技术结论

本方案保留现有OmniAuto主链路，不做推倒重构。v1.3的调整重点是把原有交付说明升级为软件项目交付标准：明确质量属性、安全边界、可靠性策略、验收口径和变更规则。核心交付标准为系统能正常回复或触发人工接管；性能指标作为优化目标，不作为未经压测的硬承诺，最终以测试环境实测数据为准。