

AI智能客服售前跟进系统

技术方案手册（软件项目交付标准版）

项目定位	抖音小风车手机号线索驱动的个人微信AI销售预跟进系统
文档版本	v1.8
文档日期	2026-05-24
预算基线	87,000元（58人天 × 1500元/人天）
实施周期	6-8周
范围基线	第一期正式工程版本；后续SaaS化、复杂权限、计费和高可用另行评估
交付口径	按软件项目标书式交付：范围、质量、验收、缺陷、变更、交付物均可追踪

本手册用于立项、开发、测试、灰度、验收和后续变更管理。除双方书面确认外，本文档与报价单共同构成本期正式工程交付基线。

1. 项目目标与第一性原理

本项目的本质不是建设一个通用聊天机器人，而是建设一个“线索到销售接管”的工程系统。AI的职责是提升首次响应、暖场、识别意向和减少无效沟通；最终成交仍由真人销售完成。

- 业务目标：将抖音小风车手机号线索更快、更稳定地推进到销售接管。
- 工程目标：让线索状态、会话绑定、AI回复、图文识别、风控接管和失败追踪形成闭环。
- 设计原则：保留必要复杂度，避免把一期工程版本扩展成完整SaaS、复杂坐席系统或通用AI平台。
- 边界原则：模型只生成候选表达和理解结果，业务事实、敏感字段和最终发送权必须受系统规则约束。

2. 一期正式工程范围基线

类别	内容	验收口径
包含	手机号线索导入、销售分配、个人微信手机号加好友、备注绑定、文字AI回复、图片另存、视觉理解、图文自动回复、本地车源索引、大风车基础适配、销售接管、自动召回、日志与失败重试	以端到端闭环演示和验收用例通过为准
不包含	完整SaaS、多租户计费、复杂权限、抖音官方API、复杂BI、模型微调平台、高可用集群、长期运维、完整坐席系统	不作为本期验收项；新增时走变更流程
甲方前提	商家侧测试电脑、测试销售微信、销售微信手机客户端、小风车线索样本、大风车参数、千问视觉API Key、销售接管规则、图片测试样本	未按期提供时，交付周期相应顺延


3. 质量属性与非功能要求

质量属性	工程要求	一期验收基线
功能性	覆盖线索导入、分配、加好友、会话绑定、文字回复、图片回复、转人工、审计	A类验收用例通过；核心流程可重复演示
性能效率	实时对话链路不做重型同步外部依赖；车源查询优先本地索引	性能数值仅作为优化目标，不作为未经压测的硬验收承诺；最终以测试环境实测数据为准
兼容性	明确Windows、微信桌面端、模型API、大风车API的适配边界	指定测试环境通过；版本升级需回归测试
易用性	销售使用微信手机客户端正常接管；Worker使用商家侧电脑上的微信桌面客户端执行自动化；管理员可查看任务、失败原因和基本状态	无需销售理解AI后台即可使用
可靠性	任务幂等、失败重试、Worker心跳、断点恢复、模型失败降级	灰度验收时S1缺陷为0；失败任务可追踪
安全性	手机号、图片、密钥、车主隐私和底价信息分级处理	敏感字段不进入AI可见上下文；日志不明文记录密钥
维护性	模块边界清晰，配置、Prompt、规则、接口适配分层	新增模型/车源适配不改动核心状态机
可移植性	本地Worker、模型Provider、车源Provider通过适配层隔离	更换模型或部署机器时保留主业务状态

性能指标口径

本期正式工程版本的核心交付标准是系统能根据客户消息正常回复，或在无法安全回复、识别失败、命中风险规则时触发人工接管。文字回复、图片回复和管理页查询的具体耗时可作为灰度阶段优化目标，但不作为未经压测的硬性验收承诺，最终以测试环境、账号状态、网络质量、模型服务和真实样本的实测数据为准。

4. 总体架构




系统保持“业务控制面 + 本地RPA Worker + OmniAuto AI引擎 + 图片理解 + 车源索引 + Guard接管”的六层边界。该设计的核心是让微信操作、AI生成、业务状态和风控规则互不混杂，便于测试、排障和后续扩展。

主流程
手机线索 -> 销售分配 -> 加好友任务 -> 微信备注绑定 -> 会话监听 -> OmniAuto生成候选回复 -> Guard检查 -> 自动回复或人工接管 -> 审计记录

5. UML全流程

下图采用UML活动图口径表达全流程。销售人工接管发生在微信手机客户端；Worker运行在商家侧电脑，控制同一销售微信号登录的微信桌面客户端。两端共用同一微信账号，因此转人工后Worker必须停止自动回复和主动操作，避免与销售手机端人工回复形成并发冲突。



6. 模块边界与职责

模块	主要职责	不得承担的职责
业务控制面	线索、销售、任务、状态、审计、配置	不直接操作微信UI
本地Worker	承载加好友任务类型、聊天回复任务类型、自动召回任务类型、微信UI锁、心跳上报和本机执行台	不保存业务主状态，不把不同任务类型的业务逻辑耦合
OmniAuto AI引擎	上下文管理、RAG、候选回复生成、图文回复编排	不直接读取底价/车主隐私，不绕过Guard发送
AI Reply Provider Adapter	预留Dify/FastGPT/其他模型工作流接入	不作为第一期业务主状态库
图片/视觉模块	图片保存、视觉识别、结构化ImageIntent	不直接生成最终客服话术
车源服务	同步大风车、清洗字段、建立本地索引、字段白名单	不把敏感价格和车主隐私传给AI
Guard/接管	风险判断、停止规则、转人工、发送前校验	不依赖单一Prompt判断高风险

Worker任务类型拆分

Worker任务类型	只负责的业务	不负责的业务
add_friend	领取加好友任务、手机号搜索、发送好友申请、写入初始绑定备注、回传申请结果	不监听客户对话，不调用AI生成回复，不判断客户意向
chat_reply	监听已绑定会话、读取文字/图片、图片另存、调用OmniAuto、Guard检查、发送AI回复、触发人工接管、触发飞书机器人通知	不批量加好友，不修改转人工备注，不处理线索分配
follow_up	按召回规则生成再触达任务，发送固定召回文案，记录召回结果	不负责实时聊天回复，不自行判断成交，不绕过风控策略
Local WeChat UI Lock	同一台商家电脑、同一个微信桌面客户端的所有UI操作必须串行执行	不是业务模块，不决定客户状态；只负责避免两个任务类型抢微信窗口

拆分原则

- 两个任务类型可以运行在同一个Worker进程或同一台商家侧电脑上，第一期不要求物理拆分。
- 两个任务类型使用独立任务队列和独立状态机，业务逻辑互不依赖。
- 两个任务类型共用同一个Local WeChat UI Lock；只有真正操作微信桌面端时需要抢锁。
- 非UI工作如AI生成、图片识别、车源查询、日志记录可以并行执行。

7. 本地Worker可视化执行台

Worker不应设计成完全不可见的后台脚本。第一期应参照“微信桌面客户端 + 本地执行台”的形态：商家侧电脑打开该销售微信号登录的微信桌面客户端，旁边展示Worker执行台；销售人工接管主要通过自己的微信手机客户端完成。执行台展示当前客户、任务步骤、视觉截图、AI处理结果、发送结果和运行控制。

区域	内容	验收口径
任务状态	显示当前线索、绑定销售、微信会话、执行阶段、成功/失败状态	销售或管理员能判断当前Worker正在做什么
步骤时间线	按顺序展示检查微信、读取消息、图片另存、视觉识别、回复生成、发送完成、转人工、飞书通知等步骤	每一步有状态和时间，不只显示最终结果
画面证据	保留当前微信窗口截图或图片缩略图，用于确认识别对象	排障时能看到当时处理的是哪条消息/哪张图片
AI结果	展示视觉理解摘要、候选回复、Guard结论、最终发送内容	能复盘AI为什么这样回复
运行控制	提供启动、暂停、继续、停止、手动接管/禁用AI等按钮	异常时可以人工停止，不依赖杀进程

区域	内容	验收口径
健康状态	显示Worker心跳、微信连接状态、模型连接状态、车源同步状态	状态异常可见
日志入口	显示最近错误、失败原因、任务ID和会话ID	失败任务可追踪

设计约束

- 执行台只负责本机运行可视化和人工控制，不作为业务主数据库。
- 执行台需展示当前运行的Worker任务类型，例如add_friend、chat_reply或follow_up。
- 执行台不得展示采购价、销售底价、经理价、车主隐私和API密钥。
- 第一期不要求做复杂坐席工作台，只要求做到本机可观察、可暂停、可恢复、可复盘。
- 当销售通过微信手机客户端手动接管或在执行台点击停止后，该会话AI自动回复必须停止。

8. 核心数据流与状态机

对象	状态流转	关键规则
线索	new -> assigned -> add_friend_pending -> add_friend_sent -> friend_added -> ai_chatting -> handoff_required -> human_taken_over -> closed	状态变更必须记录时间、触发来源和失败原因
加好友任务	pending -> running -> sent -> failed -> expired	按任务ID幂等执行；失败可重试但不得重复骚扰客户
聊天回复任务	message_received -> preparing -> ai_generating -> guard_checking -> sent/handoff/failed	仅处理已绑定会话；转人工后不再自动回复
自动召回任务	eligible -> scheduled -> waiting_window -> sending -> sent/skipped/failed	仅对未拒绝、未人工接管、未触达上限且满足时间规则的客户执行
会话	unbound -> bound -> ai_active -> handoff_open -> human_active -> stopped	检测到销售手机客户端手动发送或系统触发转人工后AI停止；人工接管状态优先级最高
图片资产	received -> saved -> recognized -> linked -> replied/failed	保存路径、来源消息、识别结果和回复结果可追踪

9. 人工接管与通知规则

微信备注仅用于初始绑定，不作为人工接管状态的依据。人工接管状态必须以系统内部会话状态为准。转人工时系统应立即关闭该会话AI自动回复，并通过飞书机器人通知对应销售的手机端，而不是通过修改微信备注来通知。

规则	说明
初始备注	加好友或绑定阶段可写入短码备注，例如CJ-张三-A7K9-1234，用于线索与微信会话初始绑定。
转人工状态	转人工时只更新系统内部状态，如handoff_required/human_active，并立即关闭该会话AI自动回复。
飞书通知	系统通过飞书机器人向对应销售发送接管通知，通知内容包含客户标识、线索短码、触发原因、最近一条客户消息和建议动作。
不改转人工备注	转人工时不修改微信备注来表达接管状态，避免Worker在微信桌面端操作同一账号，和销售手机端人工回复形成并发冲突。
通知失败处理	飞书机器人通知失败时记录失败原因，并在控制面/Worker执行台展示告警；通知失败不应导致AI继续自动回复。
验收口径	验收以AI停止、系统接管状态正确和飞书通知触发记录为准，不以微信备注是否变更为准。

10. AI对话与RAG架构

第一期以OmniAuto作为主对话控制引擎。Dify或FastGPT可作为后续候选回复Provider接入，但不直接接管业务状态、车源敏感字段和最终发送权。

层次	职责	实现口径
知识来源	稳定知识、销售话术、二手车规则、车型资料、服务流程	进入OmniAuto知识库/RAG
动态事实	车源、价格、里程、状态、图片	来自大风车同步后的本地结构化索引
候选回复	根据上下文、知识和事实生成表达	默认OmniAuto；可通过Adapter调用Dify/FastGPT
发送前检查	敏感承诺、越权报价、车况断言、金融承诺、接管触发	由Guard执行，不能只靠模型自觉
审计	记录输入、召回、候选回复、Guard结论、最终动作	用于复盘和验收

图文回复链路
客户图片 -> RPA另存 -> 视觉模型识别 -> ImageIntent -> 本地车源索引 -> evidence pack -> OmniAuto候选回复 -> Guard -> 发送/接管

11. 自动召回模块

自动召回用于对已添加微信但处于观望状态、长期未互动且未明确拒绝的客户进行低频再触达。该模块不是实时聊天，不做AI自由发挥；第一期采用固定文案和明确规则，所有发送仍受风控策略、静默时段、每日上限、黑名单和Local WeChat UI Lock约束。

配置项	说明	一期工程口径
适用客户状态	例如观望、已添加未成交、未拒绝、未人工接管	状态由控制面维护
触发周期	例如7天未联系且无新消息	周期可配置，默认规则需双方确认
固定文案	第一期使用固定召回话术，不让模型临场自由生成	文案可配置并留痕
发送窗口	仅在允许时间段发送，避开静默时段	命中静默则延期
发送上限	受每日上限、单客户召回次数上限控制	超过上限则跳过并记录原因
排除条件	已拒绝、已成交、已转人工、黑名单、近期销售已联系、风险暂停	命中任一条件不得发送
结果记录	记录召回任务ID、规则、文案、发送时间、成功/失败/跳过原因	控制面可查询

示例规则
客户状态=观望 且 最近7天无客户消息/销售消息 且 未拒绝 且 未转人工 且 不在黑名单 -> 生成follow_up任务 -> 命中发送窗口后发送固定召回文案 -> 记录结果

12. 风控策略中心

风控策略中心参考既有自动回复产品文档与Worker执行台原型补充。本期不只依赖Prompt判断风险，而是将自动回复开关、接管、静默、限额、名单、关键词、延迟和限频做成可配置规则。配置由服务端控制面管理，Worker执行台展示当前命中状态并执行服务端返回的动作。

风控项	功能说明	一期验收口径
自动回复总开关	控制AI自动回复启用状态，可按全局/销售/会话配置	关闭后Worker不发送AI回复
人工接管模式	会话进入handoff_required/human_active后AI停止，服务端触发飞书机器人通知销售	AI停止且通知记录可追踪
静默时段	配置不自动回复的时间段，例如夜间或门店非工作时间	静默期内不主动发送AI回复，可记录待处理或转人工
每日上限	限制每日自动回复数量，可按销售微信号或Worker统计	超过上限后停止自动回复并展示原因
黑白名单	按手机号、线索短码、会话或客户标识控制允许/禁止自动回复	黑名单不回复；白名单按规则放行
关键词拦截	拦截敏感、无关、投诉、法务、退款等关键词	命中后不直接回复或转人工

风控项	功能说明	一期验收口径
人工接管关键词	命中价格底线、事故车、泡水、贷款审批、合同等关键词时触发接管	触发handoff并发送飞书通知
随机发送延迟	发送前增加可配置随机延迟，使回复节奏更自然	延迟可配置；不承诺规避微信平台风控
风险提示检测	检测微信桌面端出现操作频繁、环境异常等提示后暂停发送	暂停原因在控制面/Worker执行台可见
单会话突发限频	限制短时间内对同一客户连续回复次数	超过阈值后暂停该会话自动回复或转人工

风控执行顺序

消息进入chat_reply后，先检查总开关、黑白名单、静默时段、每日上限和单会话限频，再进行关键词拦截/接管判断；通过后才调用OmniAuto生成候选回复，并在发送前再次执行Guard检查。任何风控命中都必须记录命中规则、处理动作和时间。

13. 安全与隐私要求

类别	要求	验收方式
手机号	界面展示可脱敏；日志避免无必要全量输出	抽查日志和页面
图片	本地保存目录受控；保留周期可配置；与线索/会话建立关联	检查配置和样本记录
密钥	大风车、模型API Key不得写入代码和普通日志	代码与日志抽查
车源敏感字段	采购价、底价、经理价、车主姓名、身份证、银行卡不得进入AI上下文	构造测试用例验证
Prompt与规则	不得向客户暴露系统提示词、内部规则和模型身份细节	对抗样本测试
权限	第一期只做基础管理入口；后续多角色权限另行评估	不作为本期复杂权限验收

14. 可靠性与异常恢复

场景	处理策略	验收口径
Worker离线	心跳超时标记离线，任务停止派发或进入待重试	离线状态可见
微信窗口异常	记录异常、停止当前任务、允许人工恢复后重试	失败原因可见
重复消息	按消息ID/时间/会话去重，避免重复回复	重复样本不重复发送
风控暂停	命中总开关关闭、静默时段、每日上限、黑名单、风险提示或限频后暂停发送	暂停原因可见且不继续自动回复或召回
模型超时	超时后重试或降级为固定话术/转人工	超时任务不丢失
视觉失败	图片识别失败时使用兜底话术或转人工	失败路径可追踪
大风车失败	对话优先读本地缓存；同步失败告警	接口失败不阻塞普通对话
销售接管	人工接管状态优先级最高，不被AI自动恢复覆盖；Worker不修改转人工备注；系统通过飞书机器人通知销售手机端	销售手机端发言或系统转人工后AI停止准确率100%；飞书通知触发记录可追踪

15. 兼容性、维护性与可移植性

维度	要求
运行环境	第一期以指定商家侧Windows测试电脑和指定微信桌面版本为验收环境；微信升级需回归测试。
模型供应商	通过AI Reply Provider Adapter隔离模型调用，避免把模型供应商写死在业务状态机中。

维度	要求
车源系统	通过Vehicle Provider Adapter封装大风车鉴权、字段清洗和同步任务。
配置项	销售、微信设备、最大轮次、停止规则、召回规则、风控策略、视觉模型、车源同步周期应配置化。
测试集	保留文字、图片、风控、接管、车源匹配回归样本，用于版本升级。
部署迁移	控制面数据、知识库、车源索引、运行配置和Worker安装包分离，便于迁移到新机器。

16. 验收标准

编号	验收项	通过标准
A-01	线索导入	可导入手机号线索并进入待分配状态
A-02	销售分配	线索可分配到指定销售和对应商家侧Worker/微信桌面端
A-03	加好友任务	RPA可按手机号搜索、发送固定申请语并记录结果
A-04	初始备注绑定	可生成短码备注并将微信会话绑定回线索；人工接管不修改微信转人工备注
A-05	文字回复	客户文字消息可正常自动回复；若命中风险规则则触发人工接管；回复过程记录审计
A-06	图片回复	客户图片可另存、识别并生成图文回复；若识别失败或命中风险规则则触发人工接管
A-07	车源检索	可基于本地索引返回AI可见字段，不暴露敏感字段
A-08	高风险接管	价格、车况、金融、合同等高风险场景不直接越权承诺
A-09	自动召回	观望客户满足7天未联系且未拒绝等规则时，可生成follow_up任务并发送固定文案；不满足条件时跳过并记录原因
A-10	风控策略	总开关、静默时段、每日上限、黑白名单、关键词拦截、接管关键词、随机延迟、风险提示检测、单会话限频可配置或可验证
A-11	销售停止AI	销售通过微信手机客户端手动发言后AI自动回复停止，准确率100%
A-12	失败追踪	加好友、召回、图片、模型、车源、风控暂停均可查看原因
A-13	飞书接管通知	系统转人工时可触发飞书机器人通知对应销售，并记录通知结果；通知失败可见且AI仍停止
A-14	Worker任务类型解耦	add_friend只负责加好友；chat_reply只负责聊天回复；follow_up只负责自动召回；三者共用Local WeChat UI Lock且不同时操作微信窗口
A-15	Worker执行台	可查看当前任务、Worker任务类型、步骤状态、截图证据、候选回复、Guard结论、风控命中原因，并支持暂停/停止
A-16	灰度验收	核心交付标准为能正常回复或触发人工接管；试运行期间S1缺陷为0；S2缺陷修复或双方确认规避

17. 缺陷等级、变更与交付物

等级	定义	处理要求
S1	核心链路不可用，如无法加好友、无法监听、无法发送回复、AI无法停止	阻塞验收，必须修复
S2	核心功能部分失败或存在明显业务风险，如图片链路不稳定、接管状态错误	验收前修复或书面确认规避方案
S3	非核心缺陷，如界面文案、轻微日志展示问题	不阻塞验收，进入遗留清单
S4	优化建议或新增需求	不计入本期缺陷，进入变更或二期需求

变更控制

- 本手册、报价单、验收清单共同构成本期范围基线。
- 新增渠道、完整SaaS、多商户隔离、模型微调、复杂BI、长期运维等均视为范围变更。
- 变更需记录内容、原因、影响模块、追加人天、排期影响和确认人。
- 未经书面确认的口头需求不作为验收依据。

交付物	内容
程序与配置	控制面、Worker、AI配置、车源同步配置、Guard规则配置、风控策略配置、召回规则配置
测试材料	端到端验收用例、图片样本、风控样本、回归测试结果
部署材料	部署步骤、环境要求、启动/停止方式、常见故障处理
交付记录	缺陷清单、变更记录、验收记录、遗留问题清单

18. 里程碑与当前不做事项

阶段	周期	交付物
P1 启动与基础闭环	第1-2周	线索导入、销售分配、加好友任务、备注规则、任务状态
P2 文字AI闭环	第3-4周	文字回复、上下文绑定、停止规则、审计、基础Guard、风控策略和自动召回规则
P3 图片与图文回复	第5-6周	图片另存、视觉识别、ImageIntent、图文回复、回归样本
P4 车源与灰度验收	第7-8周	大风车基础适配、本地索引、灰度测试、交付文档

当前不做事项

- 不做完整SaaS平台、多租户计费 and 复杂权限。
- 不做大模型微调平台和GPU训练平台。
- 不做全渠道坐席系统和复杂BI报表。
- 不把Dify/FastGPT作为第一期业务主状态系统。
- 不承诺规避微信平台风控或提升微信好友通过率。

19. 技术结论

本方案保留现有OmniAuto主链路，不做推倒重构。v1.8的调整重点是把原有交付说明升级为软件项目交付标准：明确质量属性、安全边界、可靠性策略、自动召回、风控策略中心、验收口径、变更规则、Worker可视化执行边界和Worker任务类型解耦。核心交付标准为系统能正常回复、按规则自动召回或触发人工接管；人工接管以系统内部状态为准，并通过飞书机器人通知销售手机端，不通过修改微信备注通知；性能指标作为优化目标，不作为未经压测的硬承诺，最终以测试环境实测数据为准。