

AI智能客服售前跟进系统

技术方案手册（详细设计全量版）

文档版本	v2.2
文档日期	2026-05-24
预算基线	87,000元（58人天 × 1500元/人天）
文档用途	软件项目标书式详细设计、研发拆解、验收用例和范围变更基线
交付核心	能正常回复、按规则自动召回、无法安全回复时触发人工接管；性能指标仅作为优化目标

本版将前序讨论的每个模块详细内容完整整理入文档。后续可继续修订，但本版先保证模块、边界、状态、异常、验收和待确认事项不遗漏。

1. 总体架构与交付原则

- 系统本质是“ 线索到销售接管 ”的售前跟进系统，不是通用聊天机器人。
- 云端业务控制面负责状态、任务、配置、AI、RAG、车源、风控、飞书通知和审计。
- 商家侧Worker负责微信桌面端操作、消息采集、图片另存、回复发送和本地可视化执行台。
- 销售人工接管发生在销售微信手机客户端；Worker控制商家侧电脑上同一销售微信号登录的微信桌面客户端。
- 大模型与视觉模型调用均放服务端；Worker不持有模型API Key、大风车密钥、飞书密钥和完整知识库。
- 转人工不修改微信备注；接管状态以系统内部状态为准，通过飞书机器人通知销售手机端。
- 任何断网、重启、超时、恢复场景，不得重复发送同一条AI回复或召回文案。

场景	状态	动作
普通聊天达到20条AI回复上限	watching	AI停止，不触发飞书，不关闭线索，可进入召回候选
高风险/高意向/接管关键词	handoff_required	AI停止，飞书机器人通知销售
销售手机端人工回复	human_active	AI停止，后续客户消息不再自动回复，不再召回
客户明确拒绝	rejected	不自动处理，后续重复导入也不自动加好友/回复/召回
人工确认结束	closed	线索关闭，不再进入自动流程

2. 模块1：云端业务控制面

2.1 模块目标

- 作为业务状态中心、任务调度中心、配置中心和审计中心。
- 统一管理线索、销售、Worker、任务、会话、风控、召回、飞书通知和日志。
- 第一期做轻量后台，由项目方自己控制，不做复杂权限和复杂CRM。

2.2 不做事项

- 不做多商户计费、复杂权限、完整CRM、复杂BI、多渠道客服聚合、销售业绩管理、合同订单系统、高可用集群。
- 不直接操作微信UI，不保存Worker本地临时状态为主状态。

2.3 核心子模块与对象

子模块/对象	说明
Lead	手机号线索，包含phone、phone_hash、source、sales_id、worker_id、status、remark_code、last_contact_at、reject_flag、recall_count等。
Sales	销售人员，包含sales_id、sales_name、wechat_account、worker_id、feishu_user_id、enabled、daily_add_friend_limit等。
Worker	商家侧电脑执行器，包含worker_id、device_name、sales_id、wechat_status、last_heartbeat_at、current_task_type等。
Task	统一任务表，task_type包含add_friend、chat_reply、follow_up，状态包含pending、running、succeeded、failed、skipped、cancelled。
Conversation	微信会话业务状态，包含lead_id、sales_id、ai_enabled、status、reply_count、handoff_reason等。
RiskPolicy	风控策略配置。
HandoffEvent	人工接管与飞书通知事件。

2.4 核心流程

线索入库 -> 分配销售 -> 绑定Worker -> 创建add_friend任务 -> Worker执行 -> 回传结果 -> 更新线索/任务状态
Worker上报客户消息 -> 控制面检查会话和风控 -> AI/RAG/Guard -> 返回send_reply/handoff/no_action/pause -> Worker执行 -> 审计
watching客户每日扫描 -> 满足N天未联系且未拒绝 -> 创建follow_up任务 -> Worker发送固定文案 -> 记录结果

2.5 已确认决策与待确认

事项	口径
登录权限	第一期轻量后台，项目方自控，不做复杂权限。

事项	口径
销售Worker关系	一对一绑定，允许换绑，换绑需留痕。
分配策略	待定，预留手动分配和轮询分配。
飞书通知	只做飞书，定向销售个人；不做短信。
召回规则	第一期一种规则，周期可配置，默认待定。
验收重点	状态准确、任务可追踪、配置可调整、失败原因可见。

3. 模块2：Worker任务类型与本地执行台

3.1 模块目标与形态

- Worker部署在商家侧Windows电脑，负责看微信、点微信、读消息、存图片、发回复。
- Worker执行台必须呈现为本地可视化窗口，交互效果参照附件视频：微信桌面客户端旁边展示任务步骤、截图证据、AI结果、运行状态和控制按钮。
- Worker不保存业务主状态，不直接调用大模型，不持有模型、飞书、大风车密钥。
- Worker不需要开机自启，通过执行台启动按钮操作。

任务类型	职责	不负责
add_friend	手机号搜索、发送好友申请、写初始绑定备注、回传申请结果	不聊天、不调用AI、不判断意向
chat_reply	监听已绑定会话、读取文字/图片、另存图片、上传服务端、执行服务端动作	不批量加好友、不做线索分配、不改转人工备注
follow_up	领取召回任务、发送固定召回文案、上报结果	不判断召回资格、不AI自由生成文案
Local WeChat UI Lock	所有微信桌面端UI操作串行化	不决定业务状态

3.2 UI锁、优先级与恢复

- 所有点击微信、输入微信、发送微信、切换窗口、写备注、另存图片动作必须先获取Local WeChat UI Lock。
- 上传消息、等待AI、图片识别、车源查询、日志记录等非UI动作不占用UI锁。
- 任务优先级为chat_reply大于add_friend大于follow_up；add_friend优先follow_up。
- chat_reply等待服务端AI结果时不占用UI锁，add_friend可以先执行。
- Worker重启后读取本地快照并向服务端确认，以服务端状态为准恢复。
- pending_action恢复时必须检查reply_action_id未发送、未过期、会话仍允许回复、未人工接管、客户没有新消息覆盖上下文。

3.3 不重复发送硬约束

message_id/dedupe_key用于识别同一条客户消息；reply_action_id用于识别同一次服务端回复动作；sent_ack用于确认Worker已发送。已sent、已过期、上下文变化或已人工接管的动作不得补发。

3.4 执行台展示与验收

- 展示当前Worker状态、任务类型、任务ID、客户/线索短码、步骤时间线、微信/服务端连接、图片缩略图、AI候选回复、Guard结果、风控原因、飞书通知结果、错误日志。
- 提供启动、暂停、继续、停止、手动接管/禁用AI、重试、跳过按钮。
- 验收要求：看得见、停得住、查得到原因、不会重复发送、三个任务类型共用同一UI锁。

4. 模块3：线索与销售分配

- 目标：把抖音小风车手机号线索变成某个销售微信号要执行的add_friend任务。
- 第一期线索接入方式不锁死Excel、CSV或API，统一抽象为线索接入适配器；后续可接小风车/API。
- 手机号默认脱敏展示；手机号标准化后作为核心去重键。
- 同手机号一旦标记rejected，后续再次导入也不自动处理。
- 销售每日加好友上限需要配置，默认值待定。
- 分配策略待定，先预留手动分配和轮询分配。

状态/规则	说明
Lead状态	new、assigned、add_friend_pending、add_friend_sent、friend_added、ai_chatting、watching、handoff_required、human_active、rejected、closed。
任务生成条件	手机号有效、销售启用、Worker绑定、未超上限、不在黑名单、不存在未完成add_friend任务。
重复手机号	同手机号未关闭线索不重复新建有效线索，追加来源记录。
销售Worker	一对一绑定，允许换绑；新任务派给新Worker，运行中任务需人工确认。

4.1 页面与验收

- 线索列表展示手机号后四位、来源、销售、状态、最近联系时间、是否转人工、是否拒绝、召回次数、创建时间。
- 销售列表展示销售姓名、微信号、绑定Worker、飞书用户、启用状态、今日加好友数、今日AI回复数。
- 任务列表展示任务ID、手机号后四位、销售、Worker、状态、失败原因、重试次数、创建/完成时间。
- 验收：可导入/接入线索、去重、手动分配、绑定Worker、生成add_friend任务、失败原因可见、备注短码唯一。

5. 模块4：加好友 add_friend

- 目标：通过商家侧电脑微信桌面客户端，按手机号提交好友申请，并建立初始绑定标识。
- 不负责线索分配、AI聊天、自动召回、意向判断、飞书接管通知和转人工备注。
- 好友申请语最终文案待定，作为配置项；默认可支持销售姓名、门店名、线索来源变量。
- 初始备注用于线索与微信会话初始绑定，命名规则待定；转人工阶段不修改备注。
- 已是好友时立即尝试绑定会话，不重复发送好友申请。
- 加好友失败后允许人工在控制面点击重试。

状态/异常	处理
执行状态	pending、running、searching、result_detected、applying、remarking、succeeded、failed、skipped、paused。
可重试失败	wechat_not_login、wechat_window_not_found、ui_element_not_found、network_error、worker_interrupted、unknown_error。
不建议自动重试	phone_invalid、phone_not_found、already_friend、customer_privacy_blocked、wechat_rate_limit、operation_too_frequent、account_restricted、blacklist_hit、daily_limit_reached。
微信风险提示	操作频繁、环境异常、添加受限等出现后暂停add_friend并上报，不自动连续重试。
幂等	同一task_id多次上报成功只记录一次；同手机号不生成多个未完成加好友任务。

6. 模块5：会话绑定与监听

- 目标：知道微信里这条消息是谁发的、属于哪条线索、当前AI能不能回。
- 第一期不读取微信数据库、不破解协议、不使用非公开微信接口、不依赖客户昵称唯一性。
- 绑定优先通过初始备注/短码；已是好友立即尝试绑定；绑定失败不自动回复。
- 监听客户文字、图片、系统提示和我方消息；图片message type为3作为已知线索，实际实现保留兜底。
- 重复消息通过dedupe_key去重；同一dedupe_key只处理一次。

6.1 销售人工回复检测

Worker发送AI回复前登记reply_action_id、reply_text_hash、send_started_at、send_finished_at。桌面端同步出我方消息时，如果内容和时间匹配AI发送登记表，则标记ai_worker；否则视为human_sales，状态转human_active，ai_enabled=false。

6.2 重启恢复

- Worker启动后读取本地快照，再向服务端确认真实状态，以服务端为准。
- 未完成pending_action必须检查是否已发送、是否过期、是否仍允许AI、是否已有销售人工消息、是否有客户新消息覆盖旧上下文。
- 不满足条件时跳过、重新生成或转人工；禁止盲发旧回复。

6.3 消息批处理与旧回复作废规则

本规则由服务端会话调度器执行，不由大模型判断。模型只接收服务端整理后的最新message_batch和evidence_pack，用于生成候选回复。

规则	说明
单会话唯一active_batch	同一conversation_id同一时间只能有一个active_batch。
会话内合并	同一客户短时间多条消息合并为一个message_batch；合并窗口和最大等待时间配置化。
会话间排队	不同客户的batch按首条消息到达时间排队；同会话新消息更新当前batch，不改变初始排队位置。
生成中收到新消息	若A1已进入AI生成但reply_action尚未sent，A2到来后并入当前batch，旧reply_action标记superseded/cancelled，并基于A1+A2重新生成。
Worker可执行动作	Worker只能执行最新有效reply_action_id；superseded、cancelled、expired、sent状态均不得发送。
sending状态	若旧reply_action已进入sending或Worker已持有UI锁开始输入/发送，不强行取消；等待sent_ack或failed_ack，A2进入下一轮batch。
已发送后新消息	旧reply_action已sent后，新消息创建新一轮batch，不撤回已发送消息。
模型职责边界	模型不判断是否取消旧回复、不判断batch合并、不决定发送顺序，只生成候选回复。

示例：A1、B1、C1、A2依次到达。若A1尚未发送，则A_batch=[A1,A2]，B_batch=[B1]，C_batch=[C1]；发送顺序按首条消息到达时间建议为A、B、C。

6.4 验收

- 可绑定微信会话；未绑定会话不自动回复。
- 客户文字和图片可识别并上传。
- Worker发送的AI消息不会误判为销售人工回复。
- 销售手机端人工回复后AI停止。
- 同一客户短时间多条消息可合并为一个message_batch。
- 生成中但未发送的旧reply_action在新消息到来后会被superseded/cancelled，不会被Worker发送。
- 重启/断网恢复后不重复发送同一reply_action_id。

7. 模块6：AI对话模块

- 目标：根据客户消息、上下文、知识库、车源事实和规则生成候选回复或接管建议。
- 第一版模型使用DeepSeek；模型调用、RAG、车源检索、Guard均在服务端。
- OmniAuto作为主对话控制引擎，负责上下文整理、RAG调用、evidence pack消化、候选回复生成、风格控制、轮次控制。
- Dify/FastGPT Adapter第一期只预留不实现，不接管主状态。
- OmniAuto现有RAG能力需要先做代码评估；知识库资料由项目方整理。
- 模型失败直接转人工，不使用兜底话术继续自动回复。
- AI只输出候选回复和动作建议，不拥有最终发送权。

主题	设计
RAG方式	RAG + 语义检索 + 关键词加权检索。语义检索理解意思，关键词检索抓住泡水、火烧、事故、贷款、定金、底价等关键风险词。
Evidence Pack	包含conversation_context、customer_message、retrieved_knowledge、matched_cars、image_intent、risk_flags、allowed_fields。
AI可见车源字段	品牌、车系、车型、年份、里程、城市、颜色、燃料、配置摘要、对外可说价格、车辆图片。
AI不可见字段	采购价、销售底价、经理价、车主姓名、手机号、身份证、银行卡、内部备注。
动作输出	send_reply、handoff、no_action、pause、retry_later，均带reply_action_id和expire_at。
调度边界	message_batch合并、旧pending_action作废、发送顺序和幂等判断由服务端会话调度器负责，不交给模型判断。
20条上限	达到上限默认watching，AI停止，不触发飞书；风险/高意向转人工；拒绝转rejected。

7.1 Guard检查

- 检查是否承诺无事故、无泡水、无火烧，是否承诺底价、最低价、贷款包过、定金可退，是否涉及合同、赔偿、投诉、法务，是否暴露系统规则或敏感字段。
- Guard结果为pass、rewrite、handoff、block；不通过时不发送原文。

8. 模块7：图片理解与图文回复

- 图片采集在Worker本地完成，图片理解在服务端完成。
- 第一版视觉模型使用千问视觉；低置信度全部转人工。
- 客户多张图片第一期逐张处理。
- 图片本地保存路径固定可配置；保存周期配置化，默认一年。
- 云端只保存必要文件和识别结果，不做长期图片库。
- 视觉模型只负责看懂图片，不直接生成最终客服话术。

客户图片 -> Worker识别type=3 -> 点开另存 -> 上传服务端 -> 千问视觉 -> ImageIntent -> 车源索引 -> evidence pack -> OmniAuto候选回复 -> Guard -> send_reply或handoff

ImageIntent字段	说明
image_type	car_photo、car_listing_screenshot、price_screenshot、finance_screenshot、inspection_report、chat_screenshot、unrelated、unknown。
detected_vehicle	品牌、车系、车型、年份、颜色等。
detected_price	识别到的图片价格与置信度。
customer_intent	find_similar_car、ask_price、ask_condition、ask_finance、compare_car、unknown。
risk_flags	price、condition、finance、contract等。

- 图片保存失败、上传失败、视觉失败、低置信度均不强行图文回复，按规则转人工。
- 图片也必须遵守message_dedupe_key、image_dedupe_key、reply_action_id、sent_ack，避免重复识别和重复回复。

9. 模块8：大风车与车源索引

该模块整体待确认。当前阶段应向大风车提供API需求清单，对照其开放接口确认是否满足，不足部分再列沟通清单。第一期不应写死接口细节。

API需求	说明
店铺信息查询	根据shopCode查询店铺信息，确认门店权限和基础信息。
车辆ID列表	根据shopCode和operationPhase查询车辆ID，需operationPhase枚举说明和可售状态定义。
车辆详情	按carId查询品牌、车系、车型、年份、里程、颜色、配置、状态、对外展示价格等。
车辆图片	按carId查询图片URL、图片名称、图片类型、排序、大图/缩略图。
增量同步	确认是否支持按更新时间查询变更车辆、分页、车辆状态变更同步或Webhook。
鉴权与限制	确认appKey、appSecret、appId、shopCode、operator、IP白名单、频率限制、错误码、测试环境。

- 大风车作为权威车源系统，不作为图片搜车接口。
- 服务端同步后分为raw_vehicle原始数据层和vehicle_index AI可见索引层。
- AI只读白名单字段；采购价、底价、经理价、车主隐私、内部备注默认隔离。
- 同步失败保留上次成功索引，不阻塞普通聊天；鉴权失败需告警。

10. 模块9：风控策略中心

- 风控属于云端业务控制面的核心子模块，但作为独立业务模块详细设计。
- 风控策略由服务端控制面配置和判定，Worker执行服务端返回的动作，并展示命中原因。
- 第一期不承诺规避微信平台风控，不做复杂反检测和机器学习风控模型。

风控项	口径
自动回复总开关	可按全局、销售、Worker、会话控制；关闭后不自动回复和召回。
人工接管模式	handoff_required或human_active时AI必须停止。
静默时段	客户主动发消息也完全不自动回复；召回必须延期或跳过。
每日上限	AI回复、加好友、召回上限均配置化，默认待定。
黑名单	第一期支持，用于拒绝、投诉、无效、不再跟进客户。
白名单	预留或仅支持测试手机号，不能绕过高风险接管。
关键词拦截	投诉、报警、律师、退款、赔偿、诈骗、别联系等。
人工接管关键词	底价、事故、泡水、贷款、定金、合同、地址、现在定等，销售和项目方确认，最终项目方确认。
随机发送延迟	配置化，默认待定；仅体验优化，不承诺规避微信风控。
风险提示检测	操作频繁、环境异常、添加受限等出现后暂停任务并上报。
单会话突发限频	配置化，默认待定。
风险暂停恢复	支持人工解除或到期自动解除，默认人工确认更稳。

10.1 执行顺序

总开关 -> 会话状态 -> 黑名单 -> 白名单 -> 静默时段 -> 每日上限 -> 单会话限频 -> 关键词拦截 -> 人工接管关键词 -> 模型/图片/车源异常 -> Guard发送前检查

11. 模块10：人工接管与飞书通知

- 目标：AI停手，销售接上。
- 接管状态在云端控制面；飞书通知由服务端触发；Worker停止该会话自动回复并展示状态。
- 第一期使用飞书机器人定向通知销售个人，不做短信通知。
- 飞书“我已接管”按钮预留，不作为第一期必做。
- 接管后客户继续发消息不再提醒销售；销售长时间不接管不做二次自动提醒。
- 手动重发飞书通知建议保留轻量保护：管理员/项目方操作、次数限制、操作留痕、按钮确认。

触发来源	说明
风控/关键词	高风险、高意向、投诉、金融、合同、底价等。
模型失败	DeepSeek超时或失败、RAG失败、图片视觉失败、低置信度、车源失败无法安全回复。
销售主动回复	检测到销售手机端人工消息。
手动操作	控制面或Worker执行台点击停止AI/手动接管。

- 进入handoff_required时必须ai_enabled=false。
- 飞书通知包含客户标识、线索短码、手机号后四位、销售、触发原因、最近消息、建议动作、时间。
- 飞书通知失败时AI仍停止，控制面和Worker执行台展示告警，允许人工重发。
- 同一handoff_event_id不重复通知。

12. 模块11：自动召回 follow_up

- 目标：对已添加微信、处于watching、长期未互动且未拒绝的客户做低频再触达。
- 云端判断资格并生成follow_up任务，Worker只发送固定召回文案和上报结果。
- 第一期只做一种召回规则；周期默认待定，可配置为7天或14天。
- 召回固定文案待定，可配置；第一期不让模型自由生成召回话术。
- 每个客户最多召回1次；每日召回上限待定；扫描频率每天一次。
- watching第一期支持人工标记，同时支持简单规则自动标记。

规则	说明
适用客户	已加好友、会话已绑定、status=watching、未拒绝、未转人工、未关闭、未黑名单、最近N天无客户/销售消息。
自动标记watching	客户表达再看看、考虑一下、晚点说等观望，或AI达到最大回复轮次且未拒绝、未接管。
排除条件	rejected、handoff_required、human_active、closed、黑名单、近期客户/销售已联系、达到召回上限、风控暂停、静默时段。
发送	follow_up获取Local WeChat UI Lock后发送固定文案。
防重复	同一客户同一规则周期只发送一次，同一follow_up_task_id只发送一次，重启后已sent不再发送。

13. 模块12：测试、验收与部署

- 核心验收原则：系统能正常回复，或在不能安全回复时触发人工接管。
- 性能目标不作为未经压测的硬承诺，最终以测试环境、账号状态、网络质量、模型服务和真实样本实测为准。
- 测试环境包含云端控制面、数据库、AI服务、RAG/知识库、车源索引、风控配置、飞书机器人、商家侧Windows电脑、微信桌面端、Worker执行台、销售手机微信和飞书。

测试阶段	内容
P1基础链路	线索接入、销售分配、Worker绑定、add_friend、初始备注绑定。
P2文字回复	客户文字、RAG、DeepSeek、Guard、Worker发送、审计。
P3图片回复	图片另存、上传、千问视觉、ImageIntent、车源索引、图文回复或转人工。
P4风控接管	总开关、静默、上限、黑名单、关键词、模型失败、飞书通知、销售回复后AI停止。
P5自动召回	watching、N天未联系、每天扫描、固定文案、上限、跳过原因、防重复。
P6异常恢复	Worker断网/重启、服务端不可用、AI超时、重复消息、pending_action恢复、不重复发送。

13.1 S1阻塞缺陷

- 无法加好友、无法监听消息、无法发送回复、AI无法停止、重复发送同一回复、转人工后仍自动回复、敏感字段泄露。

14. 支撑模块

支撑模块	第一期口径
日志审计与数据留痕	记录任务、消息、RAG召回、候选回复、Guard、风控、飞书通知、Worker错误、人工操作，敏感字段脱敏。
配置中心与运维监控	集中管理模型、风控、召回、销售/Worker绑定、图片保留周期、车源同步等配置，展示Worker在线与同步状态。
数据安全与权限边界	第一期轻量权限；模型Key、大风车密钥、飞书配置不下发Worker；AI只读白名单字段。

15. 总待确认清单

- 线索接入方式：Excel、CSV、手动录入或API，待确认。
- 线索分配策略：手动、轮询或其他规则，待确认。
- 好友申请语最终文案，待确认。
- 初始备注命名规则，待确认。
- 每日加好友、AI回复、召回上限默认值，待确认。
- 随机发送延迟范围和单会话限频默认规则，待确认。
- 大风车API接口、字段、operationPhase枚举、可售状态和价格字段，待确认。
- 召回周期默认值、召回固定文案，待确认。
- 飞书机器人定向个人通知的具体实现方式和配置权限，待联调确认。
- 销售手机端人工回复同步到桌面端后的可读结构，需真实微信环境实测。

- OmniAuto现有RAG能力需先做代码评估。