

AI智能客服售前跟进系统

技术方案手册（正式工程版）

文档版本	v2.5
文档日期	2026-05-27
适用范围	第一期正式工程版本
核心变化	取消AI轮次上限；等待用户回复触发多轮召回；转人工后销售超时飞书通知；备注短码作为系统托管开关。

1. 核心变化

事项	旧口径	新口径
AI回复轮次	有固定轮次限制。	取消轮次上限，未拒绝、未关闭、未转人工且风控允许时持续接待。
等待用户回复	主要用于观望召回。	AI回复、人工回复、召回回复后都进入等待用户回复。
自动召回	观望客户一次召回。	等待用户回复类状态均可召回，支持多轮，受配置限制。
销售超时	不做提醒。	转人工后销售N天未回复，服务端飞书通知。
Worker职责	可能被理解为扫全微信。	只采集系统绑定会话事实，服务端负责判断。
备注短码	只作为绑定识别手段。	移除短码=关闭自动跟进；线下好友补上短码=进入系统跟进。

2. 技术栈与工程实现约束

本期按正式工程产品实施，不按演示Demo实施。技术栈选择遵循：优先复用OmniAuto现有Python能力、减少跨语言链路、保证任务可恢复、错误可定位、部署可复制、二期可演进。

层级	选型	说明
服务端	Python 3.11+ / FastAPI / SQLAlchemy / Alembic	状态机、任务调度、API、审计日志统一在服务端实现。
数据库	PostgreSQL 15+	线索、任务、会话、状态、错误码和审计日志的唯一事实源。
任务调度	PostgreSQL任务表 + lease锁 + APScheduler/扫描进程	第一阶段不引入复杂MQ；任务可恢复，防重复发送。
控制面	React + TypeScript + Vite + Ant Design	适合后台表格、表单、配置、任务看板和日志查询。
Worker桌面端	Python 3.11+ / PySide6 / wxauto4或UIAutomation / PyInstaller	复用现有RPA能力，交付Windows执行台程序。
Worker本地存储	SQLite + 本地文件目录	保存本地配置、运行日志、图片临时文件和未确认发送记录。
通信	HTTPS REST + Worker主动轮询/心跳	商家电脑不暴露公网端口；Worker拉任务、上报事实和心跳。
AI文本	OmniAuto AI Engine + DeepSeek API	OmniAuto负责上下文、RAG、Guard、编排；DeepSeek负责生成。
图片理解	千问视觉模型 + ImageIntent	识别图片内容、截图信息、车型线索和置信度；低置信转人工。
知识检索	OmniAuto RAG + 关键词/规则混合检索	Diify/FastGPT仅预留Adapter，不作为第一期核心运行时。
车源	大风车API + 本地vehicle_index	同步原始车源，AI只读取白名单字段。
日志错误码	JSON结构化日志 + error_code字典 + trace_id	控制面、Worker、服务端日志使用同一错误码体系。
部署测试	Docker Compose服务端 + Windows Worker安装包；pytest/接口集成/端到端验收	不使用Kubernetes；强调可复制部署和可验收。

明确不采用：Diify作为第一期核心对话运行时、Kubernetes、服务网格、复杂微服务拆分、多商户SaaS、复杂权限、计费、高可用集群、读取或破解微信数据库、非公开微信协议。

3. 会话主状态

状态	含义	当前等待谁	允许动作
ai_active	AI正常接待。	客户/AI	客户来消息后AI持续回复，不设轮次上限。
waiting_user_reply	AI已回复，等待客户回。	客户	到期生成召回任务。
recalled_waiting_user	AI已发召回，继续等待客户回。	客户	到下一周期可再次召回。
waiting_sales_reply	AI已转人工，等待销售回复客户。	销售	销售超时未回则飞书通知。
sales_replied_waiting_user	销售已回复，等待客户回。	客户	到期可由AI发送召回内容。
rejected	客户拒绝或黑名单。	无	停止自动动作。
closed	系统停止自动跟进，常见原因包括销售移除备注短码、销售线下接手、人工确认结束。	无	停止AI、召回、飞书提醒和主动关注。

4. 状态流转规则

客户发消息 -> Worker上报message_event -> 服务端判断可AI回复 -> AI生成回复 -> Worker发送 -> sent_ack -> 状态=waiting_user_reply。命中高风险、高意向、模型失败、图片低置信或证据不足时，进入waiting_sales_reply。

等待用户回复超过N天且客户未回复、未拒绝、未关闭、未命中静默和上限规则时，服务端创建follow_up_task；Worker发送AI召回内容，发送成功后状态=recalled_waiting_user。
waiting_sales_reply超过N天且sales_first_reply_at为空时，服务端发送飞书通知销售。飞书只做通知和错误日志，不做按钮、二次发送功能或复杂权限。

5. 备注短码工具与线下线索接入

第一期不额外给销售做关闭客户的后台工具。备注短码作为系统托管开关：备注仍包含短码，系统继续托管；备注移除短码，系统进入closed；线下好友补上短码，Worker识别后进入系统跟进。

场景	规则	结果
销售移除短码	已绑定会话备注不再包含remark_code。	status=closed，AI/召回/销售超时提醒全部停止。
线下好友启动	销售用短码工具生成remark_code，并把好友备注改成包含短码。	Worker识别短码并上报，服务端创建/绑定线索和会话。
短码唯一性	remark_code全局唯一，不能绑定多个有效会话。	避免串客和误绑定。
短码消失含义	表示销售接手或不需要系统继续管。	不等于客户拒绝，不进入rejected。

6. Worker与服务端定时扫描分工

扫描类型	谁做	扫什么	结果
微信事实监听	Worker	绑定会话的新消息、图片、销售人工回复、微信异常。	上报事实事件。
微信补偿扫描	Worker	近期活跃、等待用户回复、等待销售回复的绑定会话。	防漏消息。
召回到期扫描	服务端	数据库中的等待用户回复类状态。	创建follow_up_task。
销售超时扫描	服务端	waiting_sales_reply且销售未回复的会话。	飞书通知销售。
Worker健康扫描	服务端	heartbeat、last_sync_at、当前任务。	标记离线或卡住。

7. 微信UI操作串行约束

所有模拟人操作微信桌面端的动作必须全局串行，统一通过Local WeChat UI Lock控制。不得并行操作微信窗口。非微信UI逻辑可以并行，例如等待AI生成、RAG检索、图片上传、服务端状态机判断、飞书通知和日志写入。

类别	动作	规则
必须串行	手机号搜索、加好友、写备注、切换会话、点开图片、另存图片、输入/发送回复、发送召回、确认短码新增/移除。	必须先获取Local WeChat UI Lock，完成或失败后释放。
允许并行	等待AI生成、RAG/车源检索、图片上传和视觉识别、服务端定时扫描、飞书通知、日志写入。	不操作微信窗口，可并行。
优先级	chat_reply、add_friend、follow_up。	优先级可配置，但不改变微信UI串行原则。

8. 核心数据字段

字段	含义	来源
last_inbound_at	最近客户消息时间。	Worker上报客户消息。
last_outbound_at	最近我方发出消息时间。	Worker上报AI/召回/人工发送事实。
last_recall_at	最近召回时间。	Worker发送召回成功后上报。
sales_first_reply_at	转人工后销售首次回复时间。	Worker识别销售人工消息后上报。
handoff_at	进入等待销售回复时间。	服务端转人工时写入。
recall_count	已召回次数。	服务端根据sent_ack更新。
owner	当前责任方ai/sales。	服务端状态机维护。
remark_code	系统识别微信会话的短码。	服务端生成，Worker从备注中识别。
close_reason	关闭自动跟进原因。	备注短码移除、人工关闭、其他。

9. 错误码与运维可解释性原则

所有报错、失败、跳过、暂停、异常恢复都必须有稳定错误码和错误码解释说明。控制面、Worker执行台、日志审计和验收问题单展示同一error_code，不允许只展示“未知错误”。第三方原始错误可以保留，但必须映射为系统内部错误码。

字段	要求	
error_code	机器可识别错误码，稳定不随文案变化。	
error_message	面向用户/运维的简短中文说明。	
error_detail	开发排障所需上下文，可脱敏。	
severity	S1/S2/S3/S4 或 info/warn/error/fatal。	
module	wechat_worker、ai_engine、vision、dafengche、feishu、control_plane等。	
suggested_action	建议处理动作，例如重新登录微信、检查API Key、人工接管。	
trace_id	串联一次任务、一次回复或一次外部调用的追踪ID。	
错误码	含义	建议动作
WECHAT_LOGIN_EXPIRED	微信桌面端登录失效。	人工重新登录微信后恢复Worker。
WECHAT_UI_ELEMENT_NOT_FOUND	微信界面元素未找到。	检查微信版本、窗口状态或重试任务。
WECHAT_RATE_LIMIT	微信出现操作频繁/限制提示。	暂停相关任务，人工确认后恢复。
WORKER_UI_LOCK_TIMEOUT	微信UI串行锁等待超时。	检查是否有卡住任务，必要时重启Worker。
AI_MODEL_TIMEOUT	文本模型超时或调用失败。	转人工，检查模型服务和额度。
VISION_LOW_CONFIDENCE	图片识别置信度不足。	转人工，不强行回复。
DFC_AUTH_FAILED	大风车鉴权失败。	检查appKey/appSecret/IP白名单。
FEISHU_NOTIFY_FAILED	飞书通知失败。	查看飞书机器人配置和错误日志。
REMARK_CODE_CONFLICT	备注短码冲突或绑定多人。	暂停自动回复，人工核对。
SEND_RESULT_UNKNOWN	发送中断导致结果未知。	不自动补发，人工查看微信实际发送结果。

10. 新验收重点

编号	用例	通过标准
S-01	AI连续多轮接待	客户持续提问时，AI可持续回复，不因固定轮次停止。
S-02	AI回复后等待用户	AI发送成功后状态进入waiting_user_reply。
S-03	人工回复后等待用户	销售人工回复被Worker识别后，状态进入sales_replied_waiting_user。
S-04	等待用户超时召回	超过N天客户未回复，服务端生成follow_up_task，Worker发送召回。
S-05	多轮召回	召回后客户仍未回复，到下一周期可再次召回。
S-06	用户回复终止召回	客户回复后召回条件失效。
S-07	用户拒绝停止自动动作	客户拒绝后，不回复、不召回、不加好友。
S-08	转人工等待销售	AI转人工后进入waiting_sales_reply，AI不再自由回复。
S-09	销售超时飞书通知	销售超过N天未回复，服务端发送飞书通知并记录结果。
S-10	Worker与服务端扫描分工	Worker上报微信事实；服务端根据数据库状态生成召回和销售提醒。
S-11	移除备注短码关闭自动跟进	Worker发现已绑定会话备注短码消失后，服务端进入closed。
S-12	线下好友加短码启动跟进	销售生成短码并修改微信备注后，Worker识别并绑定，系统开始跟进。
S-13	找回原短码恢复跟进	销售误删短码后找回原短码并加回备注，系统恢复原会话和历史上下文。
S-14	微信UI操作串行	同时存在多个微信UI任务时，Worker必须按Local WeChat UI Lock串行执行。
S-15	错误码可解释	任意失败、暂停、跳过、异常都必须展示稳定错误码、错误说明和建议处理动作。